

CIM と他アルゴリズムの「出力解の多様性」評価

実施日: 2026-08-18 / 実行機: desktop (DESKTOP-02D2QIU, Windows, NUMBA_NUM_THREADS=4) 成果物: results/2026-08-18/solution_diversity/v2_G22_K2000_G55_G70_nt32_main/

図中心の読みやすい要約版は [RESULTS_visual_v1.md](#) / [RESULTS_visual_v1.pdf](#)。本書は全数値・全条件を載せた詳細版。

1. 問いと結論の要約

問い: CIM は他のソルバと比べて「どれくらいバラバラの解」を出すのか。その多様性は 本物（別の谷を見つけている）なのか、単に収束していないだけなのか。

結論:

- 6 手法の中で見れば、CIM はむしろ多様性の低い側**（4 インスタンスの平均順位 4.25 / 6 位。3.1.1）。CIM が上位に来るのは疎で小さい G22 だけで（2 位、距離 0.327、固定頂点わずか 0.8%）、K2000 で 4 位、G55 で 5 位、**G70 では 6 位＝最も凝集する**。一貫して多様なのは PT-ICM（平均 1.75 位）、一貫して凝集するのは dSB（5.75 位）。「CIM＝バラバラな解を出す」は G22 に限った現象である。
- ただし多様性と品質はおおむね逆行する**。「平均 gap が大きい手法ほど解が散らばる」傾向が 4 インスタンスすべてで見られる（手法 6 点での Spearman $\rho = 0.94 / 0.94 / 0.66 / 0.83$ 、G22・K2000 は $p = 0.005$ 、G70 は $p = 0.042$ 、G55 は $p = 0.16$ で有意ではない）。CIM の多様性は **上位解の周辺ではなく、やや外側の広い領域に散っている**（G22 で上位 25% に CIM の解は 0 本）。
- それでも「収束不足のゆらぎ」ではない**。全手法の出力を **共通の Tabu Search で磨く** 対照実験を行っても、平均距離はほとんど動かない（CIM K2000: 0.446 $\rightarrow$ 0.444、dSB: 0.313 $\rightarrow$ 0.318）。磨きは品質を大きく改善する（CAC K2000: gap 26.1% $\rightarrow$ 2.1%）のに距離は残る。**各手法は構造的に別々の場所へ着地している**。
- 多様性の意味はインスタンスの構造で反転する**。疎な G22 は強い big valley（上位解どうしの距離が 0.07 しかない）なので「多様＝上位解から離れている＝損」。一方、密な K2000 では **上位 25% の解ですら互いに 0.30～0.37 離れている**（高品質解が多数縮退）ので、多様性は探索資源として意味を持つ。
- 手法間でも領域が違う**。G22 で PT-ICM はどの手法からも 0.37～0.39、CIM は 0.30 離れており、dSB/GA/CAC の 3 手法が互いに 0.18～0.21 で固まっているのと対照的。ポートフォリオで「別の場所を見る係」は CIM と PT-ICM が担えるが、その場所の品質は低い。

2. 実験設定

2.1 対象

- 手法 (6) : CIM / CAC / SA / SB(dSB) / PT-ICM / GA(memetic)。実装・パラメータは `scripts/benchmarks/algo_registry.py` (`results/anytime_tuned_params.json` の Optuna 調整値を適用)。
- インスタンス (4) : G22 (n=2000, 疎, 非重み) , K2000 (n=2000, 密, ± 1 重み) , G55 (n=5000, 疎) , G70 (n=10000, 疎)。
- 独立シード 32 本 (seed = 0..31) を 1 バッチで実行し、返ってきた解ベクトルを全保存。

2.2 実時間を揃える

多様性は計算時間に強く依存するので、手法間で**バッチ実時間を揃える**。予算グリッド (`BUDGET_GRIDS`) を昇順に走らせ、**目標秒を超える直前の予算を採用**した (目標: G22 20 s / G55・G70 30 s / K2000 120 s)。採用予算と実測時間は表 1 に併記。実時間は G22 で 7.6~15.6 s、K2000 で 61~159 s の範囲に収まっている (PT-ICM の K2000 だけは最小予算でも 159 s 掛かるため超過)。

2.3 指標

MAX-CUT の解は分割なので、**全体反転 $s \rightarrow -s$ は同一解**。すべての距離はこの対称性を畳む:

$$d(a, b) = \frac{\min(H(a, b), n - H(a, b))}{n} \in [0, 0.5]$$

- **平均ペアワイズ距離**: 32 本から作る 496 ペアの平均。0 = 全部同じ解、0.5 = 無相関 (下記 2.4 に手順)。
- **相異なる解の個数**: 全体反転を同一視した上での相異なる分割の数。
- **固定頂点の割合**: 最良解に揃えた上での磁化 m_i が $|m_i| \geq 0.9$ の頂点の割合。「どの試行でもほぼ同じ側に決まる」骨格の大きさ。
- **エントロピー**: 頂点あたりの平均二値エントロピー [bit]。1 bit = 完全にランダム。
- **1-opt 局所最適率**: 出力解のうち「1 頂点反転で改善できない」ものの割合。
- **FDC**: 見つかった最良解からの距離と gap の相関係数 (big valley の強さ)。

実装: `scripts/benchmarks/diversity_metrics.py`。

2.4 平均ペアワイズ距離の計算手順

1. **解の収集**: 1 手法 $\times$ 1 インスタンスにつき、シード $0, 1, \dots, 31$ の $T = 32$ 本を 1 バッチで実行し、返ってきた解ベクトルを $s^{(1)}, \dots, s^{(T)} \in \{0, 1\}^n$ として保存する (各モジュールの返り値は

bool / ± 1 / 0-1 とまちまちなので `> 0` で 0/1 に統一。 `to_binary`)。

2. **ハミング距離**: 順序を区別しないすべてのペア $i < j$ ($\binom{32}{2} = 496$ 組) について

$$H_{ij} = \sum_{v=1}^n \mathbb{1} [s_v^{(i)} \neq s_v^{(j)}]$$

実装は 0/1 行列 X に対する行列積 $H = X(1 - X)^T + (1 - X)X^T$ で一括計算する

(`hamming_matrix`)。 3. **全体反転の同一視**: MAX-CUT の解は分割なので s と $1 - s$ は同じ解。そこで

$$d_{ij} = \frac{\min(H_{ij}, n - H_{ij})}{n}$$

と折り返す (`distance_matrix`)。値域は $[0, 0.5]$ 。 4. **平均**: 上三角のみ ($i < j$) を取り、自己ペア $i = j$ を除いて単純平均する。

$$\bar{d} = \frac{1}{\binom{T}{2}} \sum_{i < j} d_{ij}, \quad \binom{32}{2} = 496 \text{ 組}$$

`summarize()` の `mean_pairwise` がこの値。中央値・最小・最大も同じ 496 個から取る

(`median_pairwise` / `min_pairwise` / `max_pairwise`、箱ひげ図もこの 496 点を描いている)。

補足:

- **手法間距離** (3.2 のヒートマップ非対角) は 2 つの集合 A, B の全組み合わせ $32 \times 32 = 1024$ 組の平均 (`cross_distance_matrix`)。対角は上の手法内平均 (496 組) なので、対角と非対角で組数が異なる。
- **部分集合に絞った距離** (`near_mean_pairwise`、上位 25% の平均距離) は、条件を満たす解だけを抜き出してから 同じ手順を適用する。
- **ランダム分割どうしの基準値**: $H \sim \text{Binomial}(n, 1/2)$ なので **min** で折り返した期待値は $0.5 - \sqrt{1/(2\pi n)}$ となり、厳密には 0.5 をわずかに下回る (実測: $n=2000$ で 0.491、5000 で 0.494、10000 で 0.496)。図中の 0.5 の線は**上限**を示すもの。
- 相異なる解の個数は、先頭要素が 0 になるよう反転を揃えて (`canonicalize`) から一意な行を数える。

3. 結果

3.1 生の出力の多様性 (表 1)

インスタンス	手法	採用予算	実時間[s]	平均gap[%]	最良gap[%]	平均距離	相異解	固定頂点[%]	エントロピー[bit]	1-opt局所最適[%]
G22	CIM	4800	11.3	0.402	0.127	0.327	30/32	0.8	0.751	69
G22	CAC	4000	7.6	0.175	0.022	0.214	32/32	33.5	0.490	34
G22	SA	10000000	9.3	0.126	0.007	0.255	32/32	15.8	0.575	100
G22	dSB	6000	11.6	0.072	0.007	0.160	32/32	35.8	0.382	100
G22	PT-ICM	80	8.9	0.818	0.531	0.414	32/32	0.1	0.894	0
G22	GA	20	15.6	0.080	0.007	0.175	32/32	43.5	0.406	100
K2000	CIM	300	61.1	3.218	2.187	0.446	32/32	0.1	0.944	0
K2000	CAC	500	97.4	26.073	4.275	0.473	32/32	0.0	0.965	0
K2000	SA	1000000	61.1	5.407	3.759	0.465	32/32	0.0	0.969	100
K2000	dSB	400	79.4	0.515	0.177	0.313	31/32	15.6	0.662	47
K2000	PT-ICM	30	159.3	6.730	5.912	0.466	32/32	0.0	0.964	3
K2000	GA	20	101.4	0.373	0.000	0.375	32/32	3.6	0.796	100
G55	CIM	9600	21.7	1.156	0.719	0.387	32/32	0.1	0.867	88
G55	CAC	12000	14.6	0.646	0.485	0.438	32/32	0.0	0.928	3
G55	SA	30000000	16.4	0.306	0.155	0.410	32/32	0.1	0.892	100
G55	dSB	15000	16.6	0.265	0.146	0.376	32/32	1.3	0.827	100
G55	PT-ICM	200	28.6	1.070	0.845	0.440	32/32	0.0	0.952	0
G55	GA	8	22.2	2.111	1.622	0.469	32/32	0.0	0.963	100
G70	CIM	4800	17.8	1.161	0.938	0.381	32/32	1.3	0.825	62
G70	CAC	4000	6.2	1.559	1.157	0.475	32/32	0.0	0.969	78
G70	SA	30000000	13.9	0.761	0.584	0.457	32/32	0.0	0.966	97
G70	dSB	15000	20.4	0.571	0.469	0.449	32/32	0.0	0.953	100
G70	PT-ICM	80	17.5	2.014	1.804	0.481	32/32	0.0	0.975	62

インスタンス	手法	採用予算	実時間[s]	平均 gap[%]	最良 gap[%]	平均距離	相異解	固定頂点 [%]	エントロピー [bit]	1-opt 局所最適 [%]
G70	GA	3	24.4	4.063	3.618	0.487	32/32	0.0	0.973	100

図: G22_pairwise.png (手法別のペアワイズ距離分布), G22_frozen.png (固定頂点率とエントロピー), quality_diversity.png (4 インスタンスの品質 × 多様性)。他インスタンスも同名パターンで用意。

読みどころ:

- **32 本中 30～32 本が相異なる解**。どの手法もインスタンスも「毎回同じ解を返す」ことは無い。ただし「相異なる」だけでは情報が薄く (1 頂点違ってても別解)、距離・固定頂点率で見る必要がある。
- **G22 では距離の序列 dSB(0.160) < GA(0.175) < CAC(0.214) < SA(0.255) < CIM(0.327) < PT-ICM(0.414)**。これは gap の序列とほぼ逆順 (手法 6 点での Spearman $\rho = 0.94$, $p = 0.005$)。ただし quality_diversity.png の G55/G70 パネルを見ると **CIM だけがこの傾向から外れて下に落ちる** (gap が中位なのに距離は最小) ので、「gap の裏返し」で全部説明できるわけではない。
- **CIM の固定頂点率 0.8%** は象徴的で、「2000 頂点のうち安定して同じ側に来るのは 16 頂点だけ」。一方 GA は 43.5% (870 頂点) が共通の骨格を持つ。
- 大規模疎 (G55/G70) では**逆転**し、CIM が最も凝集 (0.381～0.387)、GA が最も散る (0.469～0.487)。ただしここでの GA は予算 3～8 世代しか回せておらず gap 2.1～4.1% と最下位で、「多様なのではなく初期集団に近いまま散らばっている」状態である。
- **1-opt 局所最適率**は手法の性格を分ける。SA/dSB/GA の出力はほぼ常に局所最適 (100%)。CIM は G22 で 69%、G55 で 88% が局所最適だが、**密な K2000 では 0%** (平均 37 頂点が改善可能)。PT-ICM も低予算では局所最適に達していない (G22 で 0%)。

3.1.1 多様性の総合順位 (4 インスタンス通し)

インスタンスごとに平均ペアワイズ距離で順位を付け (1 = 最も多様)、その平均を取ると次のようになる。

手法	G22	K2000	G55	G70	平均順位	平均距離
PT-ICM	1	2	2	2	1.75	0.450
CAC	4	1	3	3	2.75	0.400
GA	5	5	1	1	3.00	0.377
SA	3	3	4	4	3.50	0.397
CIM	2	4	5	6	4.25	0.385

手法	G22	K2000	G55	G70	平均順位	平均距離
dSB	6	6	6	5	5.75	0.325

CIM は 6 手法の中では多様性の低い側（平均 4.25 位）である。エントロピー基準・固定頂点率基準でも順位はまったく同じ（いずれも CIM は平均 4.25 位）で、指標の取り方には依存しない。

CIM が上位に来るのは**疎で小さい G22 だけ**（2 位、距離 0.327、固定頂点 0.8%）で、K2000 で 4 位、G55 で 5 位、**G70 では 6 位＝最も凝集する**。「CIM は他手法よりバラバラな解を出す」は G22 に限った現象であって、一般則ではない。

一貫して多様なのは **PT-ICM**（4 インスタンスすべてで 1～2 位）、一貫して凝集するのは **dSB**（5～6 位）。GA は G22/K2000 では最も凝集する側だが、時間が足りない G55/G70 では最も散る（＝初期集団に近いまま）ため、順位の振れ幅が最大である。

3.2 手法間の距離（G22, 対角は手法内）

	CIM	CAC	SA	dSB	PT-ICM	GA
CIM	<i>0.327</i>	0.301	0.313	0.300	0.385	0.300
CAC	0.301	<i>0.214</i>	0.244	0.214	0.374	0.204
SA	0.313	0.244	<i>0.255</i>	0.218	0.380	0.225
dSB	0.300	0.214	0.218	<i>0.160</i>	0.377	0.177
PT-ICM	0.385	0.374	0.380	0.377	<i>0.414</i>	0.375
GA	0.300	0.204	0.225	0.177	0.375	<i>0.175</i>

図: G22_cross.png, K2000_cross.png, ...（各インスタンス）。

- **dSB・GA・CAC は互いに 0.18～0.21 と近く、ほぼ同じ谷を共有している。**
- **CIM は他手法から 0.30、PT-ICM は 0.37～0.39 離れる。**異なる領域を見ているのは事実。
- K2000 では dSB↔GA の 0.368 が最小で、それ以外はすべて 0.43 以上（ほぼ無相関）。**密インスタンスでは手法どうしが全く違う場所に着地する。**

3.3 品質を揃えた対照実験（共通 Tabu Search で磨く）

「多様に見えるのは収束していないからでは？」を潰すため、全手法の出力を**同一の Tabu Search（20000 反復・摂動なし・同一 tenure）**で磨き、同じ指標を測り直した（`diversity_refine.py`）。磨き後は全解が 1-opt 局所最適（K2000 の CAC のみ 96.9%）。

インスタンス	手法	gap前[%]	gap後[%]	距離前	距離後	磨きでの移動距離
G22	CIM	0.402	0.311	0.327	0.332	0.060
G22	CAC	0.175	0.140	0.214	0.212	0.023
G22	SA	0.126	0.122	0.255	0.254	0.008
G22	dSB	0.072	0.063	0.160	0.159	0.015
G22	PT-ICM	0.818	0.531	0.414	0.412	0.095
G22	GA	0.080	0.065	0.175	0.175	0.017
K2000	CIM	3.218	1.600	0.446	0.444	0.100
K2000	CAC	26.073	2.137	0.473	0.447	0.280
K2000	SA	5.407	2.442	0.465	0.454	0.254
K2000	dSB	0.515	0.405	0.313	0.318	0.051
K2000	PT-ICM	6.730	2.065	0.466	0.451	0.271
K2000	GA	0.373	0.351	0.375	0.375	0.019
G55	CIM	1.156	1.148	0.387	0.387	0.006
G55	CAC	0.646	0.570	0.438	0.437	0.015
G55	SA	0.306	0.306	0.410	0.410	0.000
G55	dSB	0.265	0.265	0.376	0.376	0.000
G55	PT-ICM	1.070	1.010	0.440	0.440	0.009
G55	GA	2.111	2.097	0.469	0.469	0.008
G70	CIM	1.161	1.157	0.381	0.381	0.000
G70	CAC	1.559	1.555	0.475	0.475	0.000
G70	SA	0.761	0.761	0.457	0.457	0.000
G70	dSB	0.571	0.571	0.449	0.449	0.000
G70	PT-ICM	2.014	2.005	0.481	0.481	0.000
G70	GA	4.063	4.041	0.487	0.487	0.007

この表が本実験の要である。K2000 の CAC は gap 26.1% → 2.1% と劇的に改善し、解は平均 0.280 も移動したにもかかわらず、**手法内の平均距離は 0.473 → 0.447 とほとんど縮まない**。CIM も同様（0.446 → 0.444）。つまり観測された多様性は「まだ収束していない解のノイズ」ではなく、**磨いても消えない、着地点そのものの散らばり**である。

G55/G70 では移動距離がほぼ 0 で、そもそも出力が既に局所最適だったため磨きが効いていない（この 2 インスタンスでは 20000 反復の TS は改善を見つけれない）。

3.4 上位解に絞った多様性と big valley

全手法プール（ $32 \times 6 = 192$ 解）の上位 25% だけを取り出し、その中の多様性を測った。

インスタンス	FDC(全体)	上位25%の平均距離	上位25%への寄与（本数）
G22	0.781	0.070	dSB 20, GA 17, SA 8, CAC 3, CIM 0, PT 0
K2000	0.291	0.353	GA 27, dSB 21, 他 0
G55	0.380	0.392	dSB 28, SA 22, 他 0
G70	0.301	0.452	dSB 32, SA 16, 他 0

図: `G22_fdc.png`（gap と「最良解からの距離」の散布図）, `G22_mds.png` / `K2000_mds.png`（MDS 埋め込み）。

- **G22 は教科書的な big valley**（FDC 0.78）。上位解どうしは 0.070 しか離れておらず、「良い解＝ほぼ同じ 1 個の解の近傍」。この構造では多様性は品質と直接トレードオフになる。
- **K2000 は big valley が弱い**（FDC 0.29、SA/dSB 単体では ≈ 0 ）。**上位 25% の解ですら互いに 0.353** 離れており、高品質解が多数の異なる分割として縮退している。密インスタンスでは「良い解を複数持つ」ことに実質的な意味がある。
- CIM はどのインスタンスでも上位 25% に 1 本も入らない（磨き後の G22 で 1 本のみ）。多様性の供給源にはなるが、供給される解の品質帯が上位ではない。

4. 考察

4.1 CIM の多様性はどこから来るか

CIM は各ラウンドで全パルスに独立ガウス雑音を注入し、**best-over-rounds のスナップショット**を返す。局所探索を一切持たないので、着地点は「増幅過程のどの分岐に乗ったか」で決まる。結果として G22 では固定頂点が 0.8% しかない＝**共通の骨格をほとんど持たない**。これは SA（低温で局所最適に固まる）や GA（プールが収束して 43.5% の骨格を共有する）と対照的で、「アニールして 1 点に落とす」タイプではなく「毎回ゼロから別の分岐へ落ちる」タイプであることを示す。

一方、大規模疎（G55/G70）で CIM がむしろ最も凝集する（0.381～0.387）のは、物理パラメータが G22 用に調整されたものの流用で、増幅過程が**次数の大きい頂点から先に決まる 同じ順序**を辿りやすいためと考えられる（固定頂点率自体は 0.1～1.3% と低いので、「強い骨格がある」のではなく「散らば

りの幅が他手法より狭い」)。これはパラメータ再調整で 変わりうるので、**インスタンス横断の一般則としては主張できない**。

4.2 「多様性」を評価するときの落とし穴

表 1 の Spearman $\rho = 0.66 \sim 0.94$ (うち有意なのは 3/4 インスタンス) が示す通り、**素の多様性は品質の裏返しをかなりの部分含む**。極端な例が K2000 の CAC (gap 26.1%、距離 0.473) で、これは「多様」ではなく「まだ何も解けていない」。したがって多様性の主張には最低限、

1. 実時間を揃える (本実験の 2.2)、
2. 共通の局所探索で磨いた後にも残るかを見る (3.3)、
3. 上位解に絞って測る (3.4)、

の 3 点セットが要る。この 3 つを通した後でも CIM の距離は残る (G22 で 0.332、K2000 で 0.444) ので、**CIM の多様性自体は本物**と言ってよい。問題はその多様性が置かれている品質帯である。

4.3 ハイブリッド／ポートフォリオへの含意

過去実験 (2026-06-19 の `maxcut_algo_combo`、および Q3 の「CIM 解で GA 初期集団を代用しても 到達上限は上がらない」) と本結果は整合する。

- **G22 のような疎で big valley が強いインスタンス**: 上位解は互いに 0.07 しか離れていない狭い谷に集中している。CIM が供給する 0.33 離れた解はその谷の外にあり、GA の初期集団に入れても 交叉の材料として上位解に届かない。**多様性を足しても意味が無い構造**。
- **K2000 のような密インスタンス**: 上位解自体が 0.35 離れて縮退しているので、多様性は原理的には資源になる。しかし CIM の生出力は gap 3.2% (磨いても 1.6%) で、上位帯 (dSB 0.52% / GA 0.37%) に遠く届かない。**資源として使うには品質が足りない**。
- 逆に **PT-ICM は「どの手法からも 0.37 以上離れた領域」を安定して供給する**唯一の手法で、低予算での品質は悪いが、時間を与えたときの探索先の重複が最も少ない。ポートフォリオの多様性要員としては CIM より PT-ICM の方が筋が良い可能性がある (要検証)。

4.4 副産物: 出力が 1-opt 局所最適かどうか

本実験の副産物として、各手法の出力が「1 頂点反転で改善できない」状態かを測った。SA・dSB・GA はほぼ常に局所最適、CIM は疎グラフでは 62~88% が局所最適だが **密な K2000 では 0%** (平均 37 頂点が改善可能で、TS を 20000 反復かけると gap 3.2% → 1.6%)。密インスタンスで CIM を使うなら、**出力に軽い 1-opt を掛けるだけで gap が半減する**。これは実装コストがほぼゼロの改善余地である。

5. 限界と注意

- **CIM/CAC の物理パラメータはインスタンス別調整が前提**
(`results/anytime_tuned_params.json`)。 K2000 は調整済みだが G55/G70 は G22 の定数流用 + coupling のみ調整なので、 これらでの CIM の挙動 (4.1 の凝集) はパラメータ依存の可能性が高い。
- **予算の刻みが粗いため**、実時間は完全には揃っていない (G22 7.6~15.6 s、K2000 61~159 s)。特に PT-ICM の K2000 は最小予算でも目標 120 s を超えている (159 s)。これは PT-ICM に有利な方向のズレなので、「PT-ICM が多様」という結論を弱めない。
- **32 シード**は距離分布の平均を見るには十分だが、上位 25% 部分集合 (数本~数十本) の 平均距離は誤差が大きい。厳密な主張には試行数を増やす必要がある。
- G55/G70 は全手法が未収束 (gap 0.3~4.1%) の領域での比較であり、「収束後の解の多様性」ではなく「同じ短い時間での着地点の多様性」を測っている。
- 磨き用 TS の 20000 反復は G22/K2000 には十分だが、G55/G70 では改善を見つけられず ほぼ恒等写像になっている (移動距離 ≈ 0)。この 2 インスタンスの 3.3 の行は情報量が無い。

6. 再現手順

1) 解の収集 (重いので desktop 上で実行)

```
.venv/Scripts/python.exe -u scripts/benchmarks/diversity_bench.py \  
--datasets G22 K2000 G55 G70 --num-trials 32 --tag main
```

2) 共通 TS で磨く対照実験

```
.venv/Scripts/python.exe -u scripts/benchmarks/diversity_refine.py \  
results/2026-08-18/solution_diversity/v1_G22_K2000_G55_G70_nt32_main \  
--ts-iters 20000 --out-suffix _ref20k
```

3) 図表

```
python scripts/plotting/plot_diversity.py <run_dir>  
python scripts/plotting/plot_diversity.py <run_dir> --suffix _ref20k \  
--title-note " (共通TS20000反復で磨いた後) "
```

新規コード: `scripts/benchmarks/diversity_metrics.py` (指標)、

`scripts/benchmarks/diversity_bench.py` (収集)、 `scripts/benchmarks/diversity_refine.py` (磨き対照)、 `scripts/plotting/plot_diversity.py` (図表)。

生成物

ファイル	内容
signs.npz / signs_ref20k.npz / signs_ref2k.npz	解ベクトル (32, n) と統一採点カット (生 / TS 20000 / TS 2000)
results*.json , summary*.csv , metrics*.json	指標一覧・手法間距離・FDC・上位 25% 統計
<DS>_pairwise*.png	ペアワイズ距離の箱ひげ
<DS>_mds*.png	全解の 2 次元 MDS 埋め込み
<DS>_frozen*.png	固定頂点率とエントロピー
<DS>_cross*.png	手法間の平均距離ヒートマップ
<DS>_fdc*.png	gap と最良解からの距離 (big valley)
quality_diversity*.png	4 インスタンスの品質 × 多様性
run.log , refine_*.log	実行ログ (予算探索の全点を含む)

※ 実行は desktop 上の `v1_...` ディレクトリで行い、ローカルへ取り込む際に既存の `v1_G22_nt4_smoke` (スモークテスト) と採番が衝突するため `v2_...` にリネームしている。